LAPORAN TUGAS PRAKTIKUM 4
ASSOCIATION RULE

Analisis Pola Pembelian pada Dataset Online Retail dengan Algoritma Apriori

Keterangan	Isi
Nama	Faiz Farrosian Karim
NRP	5054251027
Dataset	Online Retail (UCI Machine Learning Repository)
Algoritma	Apriori (dibandingkan dengan FP-Growth)
Pustaka	pandas, mlxtend, matplotlib, seaborn

1. Pendahuluan

Association Rule adalah teknik data mining untuk menemukan hubungan atau pola kemunculan bersama antar item dalam data transaksi. Pada praktikum ini, Association Rule diterapkan pada dataset Online Retail untuk menemukan pola pembelian antar produk. Aturan yang dihasilkan dievaluasi menggunakan tiga metrik:

- **Support** – proporsi transaksi yang memuat seluruh item pada aturan.
- **Confidence** – peluang konsekuen dibeli jika antecedent sudah dibeli.
- **Lift** – rasio confidence terhadap peluang dasar konsekuen; lift > 1 berarti hubungan positif (bukan kebetulan).

Dataset berisi transaksi ritel online sebuah toko di Inggris periode Desember 2010 sampai Desember 2011 dengan 541.909 baris dan 8 atribut: InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, dan Country. Untuk Association Rule hanya InvoiceNo (ID transaksi/basket) dan Description (item) yang dipakai.

2. Eksplorasi dan Pembersihan Data

2.1 Eksplorasi Awal

Hasil pemeriksaan awal pada data mentah ditunjukkan sebagai berikut.

Pemeriksaan	Hasil
Dimensi data	541.909 baris × 8 kolom
Missing value Description	1.454 baris
Missing value CustomerID	135.080 baris (tidak dipakai)
Invoice dibatalkan (awalan "C")	9.288 baris
Quantity ≤ 0	10.624 baris
Jumlah produk unik	4.223

Tabel 1. Ringkasan pemeriksaan data mentah

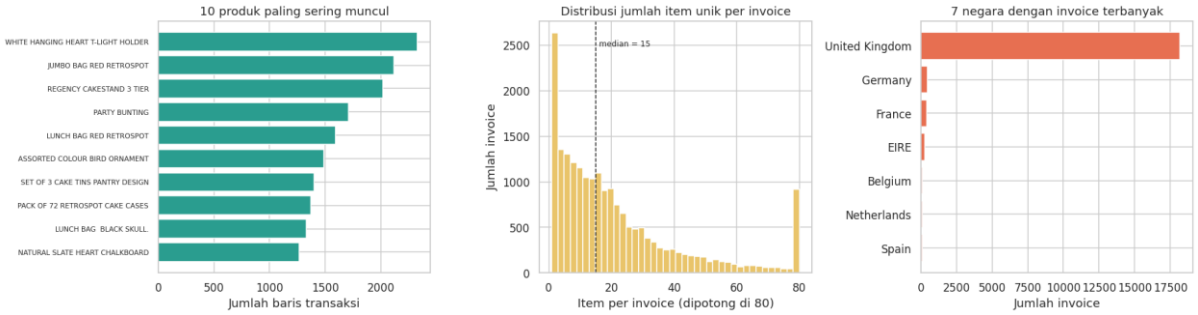
2.2 Pembersihan Data

Langkah pembersihan yang dilakukan: (1) membuang baris dengan Description kosong, (2) membuang invoice pembatalan (InvoiceNo diawali "C"), (3) membuang baris dengan Quantity ≤ 0, dan (4) merapikan spasi pada nama produk. Pembersihan ini memastikan hanya pembelian yang benar-benar terjadi yang dianalisis sehingga pola tidak terdistorsi oleh transaksi yang dibatalkan.

Ukuran	Sebelum	Sesudah	Berkurang
Jumlah baris	541.909	530.693	11.216
Jumlah invoice	25.900	20.136	5.764
Jumlah produk unik	4.223	4.065	158

Tabel 2. Jumlah data sebelum dan sesudah pembersihan

2.3 Visualisasi Eksplorasi



Gambar 1. Produk terpopuler, distribusi item per invoice, dan negara dengan invoice terbanyak

Rata-rata terdapat 25,8 item unik per invoice (median 15, maksimum 1.108), dan 90,4% invoice berasal dari United Kingdom. Distribusi ukuran basket condong ke kanan: sebagian besar transaksi kecil, sebagian kecil sangat besar, yang sesuai dengan karakter pembeli grosir.

3. Persiapan Data

Data diubah menjadi transaksi berbasis invoice, yaitu satu invoice sebagai satu basket berisi daftar produk unik. Contohnya, Invoice 536366 berisi dua item (HAND WARMER RED POLKA DOT dan HAND WARMER UNION JACK). Selanjutnya data di-one-hot encode menjadi matriks berukuran 20.136 transaksi × 4.065 produk dengan nilai True/False.

Matriks ini sangat sparse (99,36% sel bernilai False). Karena itu matriks disimpan dalam format sparse, yang menurunkan penggunaan memori dari 83 MB menjadi 3,3 MB tanpa mengubah hasil.

4. Penerapan Algoritma

4.1 Parameter Awal

Algoritma Apriori dijalankan dengan titik awal min_support = 0,01 dan min_confidence = 0,5. Hasilnya:

Keluaran	Nilai
Frequent itemset total	1.853
Ukuran 1 item / 2 item / 3 item	803 / 818 / 215
Ukuran 4 item / 5 item	16 / 1
Aturan asosiasi	841
Waktu eksekusi Apriori	1,61 detik

Tabel 3. Hasil Apriori pada min_support = 0,01 dan min_confidence = 0,5

Jumlah aturan ini (ratusan) masih dapat dianalisis, tidak terlalu sedikit maupun berlebihan, sehingga parameter awal dipertahankan.

4.2 Sensitivitas Parameter

Sebagai pembanding, parameter diubah dan jumlah aturan yang dihasilkan dicatat pada Tabel 4.

min_support	Aturan (conf ≥ 0,5)	Aturan (conf ≥ 0,7)
0,005	25.270	10.631
0,010	841	260
0,020	61	13
0,030	11	3

Tabel 4. Jumlah aturan pada berbagai kombinasi parameter

- **min_support 0,005** menghasilkan aturan terlalu banyak, didominasi pola sangat spesifik dan banyak variasi produk sejenis, sehingga sulit diinterpretasi.
- **min_support 0,02–0,03** menghasilkan aturan terlalu sedikit dan hanya memunculkan produk yang sangat populer.
- **min_support 0,01 dan min_confidence 0,5** memberi keseimbangan: aturan cukup banyak dan setiap aturan didukung sekitar 200 invoice atau lebih.

4.3 Perbandingan Apriori dan FP-Growth

Algoritma	Frequent itemset	Waktu (detik)
Apriori	1.853	1,61
FP-Growth	1.853	4,86

Tabel 5. Perbandingan Apriori dan FP-Growth (min_support = 0,01)

Kedua algoritma menghasilkan frequent itemset yang identik, sesuai teori; perbedaan hanya pada efisiensi. Pada data dan implementasi ini Apriori (dengan input sparse) justru lebih cepat. Analisis selanjutnya memakai hasil Apriori.

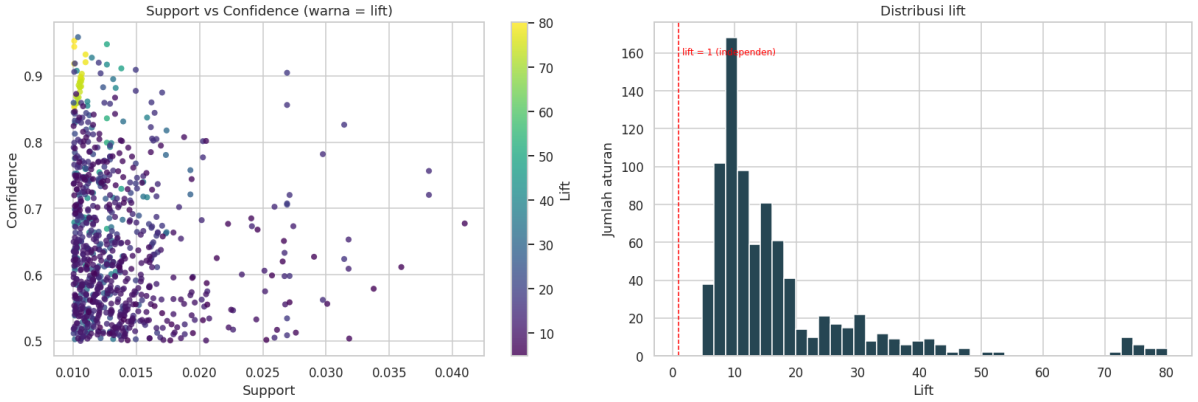
5. Evaluasi Aturan Asosiasi

5.1 Statistik Aturan

Metrik	Rata-rata	Min	Median	Maks
Support	0,014	0,010	0,012	0,041
Confidence	0,650	0,500	0,627	0,959
Lift	17,53	4,82	12,66	80,22

Tabel 6. Statistik ringkas 841 aturan

Seluruh 841 aturan memiliki lift > 1 (minimum 4,82), artinya semua aturan menunjukkan hubungan positif yang jauh di atas kebetulan.



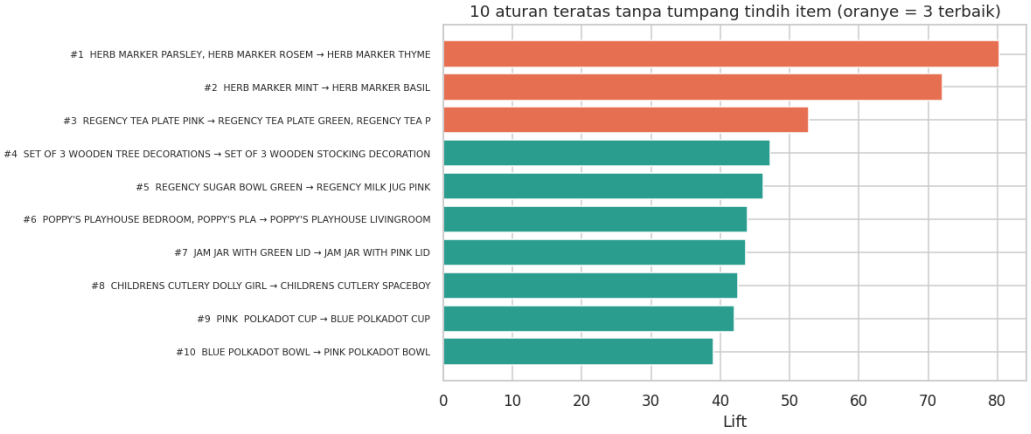
Gambar 2. Sebaran support–confidence (warna = lift) dan distribusi lift

5.2 Pemilihan Tiga Aturan Terbaik

Aturan asosiasi bersifat dua arah dan sering berulang (A→B, B→A, A,B→C, dst.) dengan lift hampir sama, terutama pada produk satu seri. Jika diambil mentah, tiga aturan teratas akan membahas produk yang sama. Karena itu dipakai pemilihan greedy: aturan diurutkan berdasarkan lift (seri: confidence), lalu aturan berikutnya diambil hanya jika tidak berbagi item dengan aturan terpilih sebelumnya. Hasilnya 10 kandidat aturan berbeda; tiga teratas adalah aturan terbaik.

No	Antecedent (jika membeli)	Consequent (maka membeli)	Supp.	Conf.	Lift
1	HERB MARKER PARSLEY, HERB MARKER ROSEMARY	HERB MARKER THYME	0,010	0,944	80,2
2	HERB MARKER MINT	HERB MARKER BASIL	0,010	0,867	72,1
3	REGENCY TEA PLATE PINK	REGENCY TEA PLATE GREEN, REGENCY TEA PLATE ROSES	0,013	0,836	52,8
4	SET OF 3 WOODEN TREE DECORATIONS	SET OF 3 WOODEN STOCKING DECORATION	0,011	0,747	47,2
5	REGENCY SUGAR BOWL GREEN	REGENCY MILK JUG PINK	0,012	0,755	46,2
6	POPPY'S PLAYHOUSE BEDROOM, POPPY'S PLAYHOUSE KITCHEN	POPPY'S PLAYHOUSE LIVINGROOM	0,011	0,716	43,9
7	JAM JAR WITH GREEN LID	JAM JAR WITH PINK LID	0,011	0,742	43,7
8	CHILDRENS CUTLERY DOLLY GIRL	CHILDRENS CUTLERY SPACEBOY	0,011	0,759	42,5
9	PINK POLKADOT CUP	BLUE POLKADOT CUP	0,010	0,678	42,0
10	BLUE POLKADOT BOWL	PINK POLKADOT BOWL	0,010	0,646	39,1

Tabel 7. Sepuluh aturan teratas berdasarkan lift tanpa tumpang tindih item



Gambar 3. Lift sepuluh aturan teratas (oranye = tiga terbaik)

5.3 Interpretasi Tiga Aturan Terbaik dalam Konteks Bisnis Ritel

Aturan #1: HERB MARKER PARSLEY, HERB MARKER ROSEMARY → HERB MARKER THYME

Pelanggan yang membeli Herb Marker Parsley dan Rosemary memiliki peluang 94% untuk juga membeli Herb Marker Thyme. Kombinasi ini muncul pada ±203 invoice (1,01% dari seluruh transaksi). Lift 80,2 berarti peluang membeli Thyme 80,2 kali lebih besar dibandingkan

peluang dasarnya. Penanda tanaman herba ini adalah satu seri yang hampir selalu dibeli lengkap.

Aturan #2: HERB MARKER MINT → HERB MARKER BASIL

Pelanggan yang membeli Herb Marker Mint memiliki peluang 87% untuk juga membeli Herb Marker Basil, muncul pada ±208 invoice (1,03%). Lift 72,1 berarti peluangnya 72,1 kali lebih besar dibanding peluang dasar. Aturan ini melengkapi seri herb marker (Mint dan Basil) sehingga seri tersebut cocok dijual sebagai satu set.

Aturan #3: REGENCY TEA PLATE PINK → REGENCY TEA PLATE GREEN, REGENCY TEA PLATE ROSES

Pelanggan yang membeli Regency Tea Plate Pink memiliki peluang 84% untuk juga membeli Tea Plate Green dan Roses, muncul pada ±255 invoice (1,27%). Lift 52,8 menunjukkan peluang 52,8 kali lebih besar dari peluang dasar. Aturan ini juga memiliki support tertinggi di antara ketiganya, sehingga paling luas cakupan transaksinya.

5.4 Implikasi Bisnis

1. **Bundling/paket produk:** produk satu seri yang hampir selalu dibeli bersama cocok dijual sebagai set dengan harga paket untuk menaikkan nilai keranjang.
2. **Penempatan dan rekomendasi:** tampilkan produk konsekuen sebagai "sering dibeli bersama" pada halaman produk antecedent dan di keranjang belanja.
3. **Manajemen stok:** permintaan produk dalam satu pola cenderung naik bersamaan, sehingga stoknya perlu dijaga seimbang agar tidak terjadi stockout pada salah satu produk.
4. **Cross-selling:** diskon pada satu produk dapat mendorong penjualan produk pasangannya.

Catatan: pelanggan dataset ini sebagian besar adalah pedagang grosir (wholesaler), sehingga pola "dibeli bersama" juga mencerminkan pembelian satu set lengkap untuk dijual kembali.

5.5 Pembanding: Aturan dengan Confidence Tertinggi

Antecedent	Consequent	Supp.	Conf.	Lift
JAM MAKING SET PRINTED, SUKI SHOULDER BAG	DOTCOM POSTAGE	0,010	0,959	27,3
HERB MARKER PARSLEY, HERB MARKER THYME	HERB MARKER ROSEMARY	0,010	0,953	80,0
REGENCY TEA PLATE PINK, REGENCY TEA PLATE ROSES	REGENCY TEA PLATE GREEN	0,013	0,948	50,1
WOODEN HEART CHRISTMAS SCANDINAVIAN, WOODEN TREE CHRISTMAS SCANDINAVIAN	WOODEN STAR CHRISTMAS SCANDINAVIAN	0,011	0,928	36,5
CHARLOTTE BAG PINK POLKADOT, STRAWBERRY CHARLOTTE BAG, WOODLAND CHARLOTTE BAG	RED RETROSPOT CHARLOTTE BAG	0,012	0,920	17,9

Tabel 8. Lima aturan dengan confidence tertinggi

Aturan dengan confidence tertinggi (95,9%) melibatkan item DOTCOM POSTAGE, yaitu biaya pengiriman, bukan produk fisik. Karena itu aturan tersebut kurang bermakna untuk strategi produk, dan ranking berdasarkan lift lebih informatif.

6. Kesimpulan

1. **Pembersihan data:** dari 541.909 baris/25.900 invoice menjadi 530.693 baris/20.136 invoice setelah membuang Description kosong, invoice pembatalan, dan Quantity ≤ 0.
2. **Persiapan:** 20.136 transaksi × 4.065 produk dalam format one-hot dengan 99,4% sel kosong.
3. **Algoritma:** Apriori dan FP-Growth menghasilkan 1.853 frequent itemset yang identik pada min_support = 0,01; dengan min_confidence = 0,5 diperoleh 841 aturan asosiasi, seluruhnya dengan lift > 1.
4. **Pola yang ditemukan:** aturan dengan lift tertinggi didominasi produk sejenis dalam satu seri (varian warna/jenis produk yang sama) yang dibeli bersamaan. Pola ini kuat dan konsisten karena lift jauh di atas 1.
5. **Rekomendasi:** manfaatkan pola tersebut untuk bundling, rekomendasi "sering dibeli bersama", dan perencanaan stok produk berpasangan.
6. **Keterbatasan:** min_support 0,01 hanya menangkap produk yang cukup populer, dan lift tinggi pada produk sejenis relatif mudah ditebak. Untuk menemukan pola yang lebih tidak terduga, support dapat diturunkan dan aturan disaring ke pasangan antar-kategori produk berbeda.