

Laporan Praktikum Data Mining

Analisis Dataset Hasil Scraping - Data Repository GitHub

Nama: Faiz Farrosian Karim | 5054251027 | Program Studi RKA, ITS

1. Deskripsi Dataset

Untuk tugas ini saya awalnya mau scraping dari situs GIGA Lab ITS, tapi setelah saya cek, situs tersebut isinya sedikit sekali (jauh di bawah 1500 baris data), jadi tidak bisa dipakai. Akhirnya saya cari sumber data lain yang datanya lebih banyak, yaitu GitHub. GitHub punya API publik yang gratis, jadi saya pakai library requests di Python untuk mengambil data repository dari sana (bukan HTML biasa, tapi tetap termasuk 'scraping data dari internet' menggunakan requests).

Data yang saya ambil adalah data repository publik dari 10 bahasa pemrograman populer (Python, JavaScript, TypeScript, Java, Go, Rust, C++, PHP, C#, Ruby), masing-masing 200 repository dengan bintang (stars) terbanyak. Total dataset yang berhasil saya kumpulkan adalah 2000 baris dan 13 kolom, jadi sudah memenuhi syarat minimal (1500 baris, 5 kolom).

Kolom-kolom yang ada: name, owner_login, owner_type (nominal), language (nominal), stargazers_count, forks_count, open_issues_count (numerik diskrit), size_kb (numerik kontinu), license_name (nominal, ada yang kosong), has_wiki, is_fork, archived (nominal True/False), dan created_at (tanggal dibuatnya repo).

2. Statistik Deskriptif

Berikut hasil perhitungan statistik dasar untuk kolom-kolom numerik (dihitung pakai pandas, fungsi describe() dan mode()):

Kolom	Mean	Median	Modus	Std Dev	Min	Max
stargazers_count	34.660	25.204	5.212	38.300	3.905	477.755
forks_count	5.182	2.773	1.647	8.014	3	108.630
open_issues_count	606	170	0	1.767	0	41.106
size_kb	292.982	46.804	582	976.058	21	17.709.400

Untuk kolom kategorikal: setiap bahasa pemrograman jumlahnya sama, yaitu 200 repo (karena memang saya ambil rata untuk tiap bahasa). Repository yang dimiliki oleh akun Organization jumlahnya 1402, sedangkan yang dimiliki akun User (perorangan) ada 598. Untuk lisensi, yang paling banyak dipakai adalah MIT (817 repo), disusul Apache-2.0 (398) dan GPL-3.0 (129).


3. Penanganan Data

Missing value: setelah saya cek pakai df.isnull().sum(), ternyata cuma kolom license_name yang ada datanya kosong, yaitu 85 baris (sekitar 4%). Setelah saya lihat-lihat lagi, itu bukan error, tapi memang repository tersebut tidak memasang lisensi apapun. Jadi saya putuskan untuk mengisi nilai kosong itu dengan tulisan "No License", bukan menghapus barisnya, supaya datanya tidak berkurang.


Outlier: saya deteksi pakai metode IQR (Q1, Q3, terus dihitung batas bawah dan atasnya) untuk 3 kolom yang menurut saya paling mungkin ada outlier, yaitu stargazers_count (ketemu 135 outlier), forks_count (163 outlier), dan size_kb (265 outlier). Outlier-outlier ini saya biarkan saja di datasetnya (tidak dihapus), karena setelah saya cek repo mana saja yang jadi outlier, itu memang repo-repo yang benar-benar populer/besar (misalnya repo public-apis dengan hampir 500 ribu stars), jadi bukan kesalahan input data, cuma sebaran datanya saja yang lebar.

- Dataset mentah: raw_github_repos.csv
- Dataset setelah dibersihkan: cleaned_github_repos.csv


4. Visualisasi & Interpretasi




Histogram jumlah stars (saya batasi di bawah 100.000 dulu supaya kelihatan bentuknya, soalnya kalau semua data dimasukkan grafiknya numpuk di kiri karena ada beberapa repo yang bintangnya sangat banyak). Dari sini kelihatan bahwa kebanyakan repository stars-nya di kisaran rendah (belasan ribu), dan semakin besar jumlah stars, jumlah repo-nya semakin sedikit. Ini sesuai dengan outlier yang saya temukan sebelumnya.




Bar chart ini menunjukkan jumlah repo tiap bahasa pemrograman. Semua sama rata 200 karena memang begitu cara saya mengambil datanya, jadi grafik ini lebih untuk menunjukkan kalau data yang saya kumpulkan seimbang antar bahasa, bukan untuk melihat bahasa mana yang lebih banyak reponya di GitHub.



Scatter plot antara stars dan forks. Terlihat titik-titiknya cenderung naik dari kiri bawah ke kanan atas, artinya repo yang bintangnya banyak biasanya juga di-fork lebih banyak orang. Masuk akal karena keduanya sama-sama menunjukkan seberapa populer/dipakai repo tersebut.



Correlation heatmap memperkuat hasil scatter plot tadi, korelasi stars dengan forks cukup tinggi yaitu 0,74. Sedangkan size_kb (ukuran repo) korelasinya kecil sekali dengan stars (0,07), jadi ukuran repo ternyata tidak terlalu berhubungan dengan seberapa populer repo tersebut.



Boxplot ini menunjukkan sebaran stars untuk tiap bahasa (masih dibatasi di bawah 100.000 juga). Terlihat Python, TypeScript, dan JavaScript median-nya lebih tinggi dibanding bahasa lain seperti PHP atau Ruby. Tiap bahasa juga masih ada beberapa titik di luar kotak (outlier) yang menunjukkan ada repo-repo tertentu yang jauh lebih populer dibanding repo lain di bahasa yang sama.

5. Kesimpulan

- Dataset yang saya kumpulkan berisi 2000 repository publik dari GitHub (10 bahasa pemrograman x 200 repo), sudah memenuhi syarat minimal praktikum (1500 baris, 5 kolom).
- Sebaran jumlah stars, forks, dan size_kb sangat lebar (right-skewed) - kebanyakan repo nilainya kecil, tapi ada sebagian kecil repo yang sangat populer/besar, dan itu yang muncul sebagai outlier saat dicek pakai metode IQR.
- Stars dan forks berkorelasi cukup kuat (0,74), jadi repo yang banyak bintangnya biasanya juga banyak di-fork. Sedangkan ukuran repo (size_kb) hampir tidak berhubungan dengan popularitasnya (korelasi 0,07).

- Missing value hanya ditemukan di kolom license name (85 baris) dan itu bukan kesalahan data, jadi cukup diisi dengan kategori 'No License', tidak perlu dihapus.
- Dari boxplot per bahasa, repo dengan bahasa Python, TypeScript, dan JavaScript cenderung punya median stars lebih tinggi dibanding bahasa lain seperti PHP atau Ruby, meskipun jumlah datanya sama rata.
- Secara keseluruhan, tahapan scraping sampai visualisasi pada praktikum ini sudah berhasil dijalankan, dan hasilnya cukup masuk akal.