Laporan Praktikum 3: Klasifikasi dengan Ensemble Method & Class Imbalance

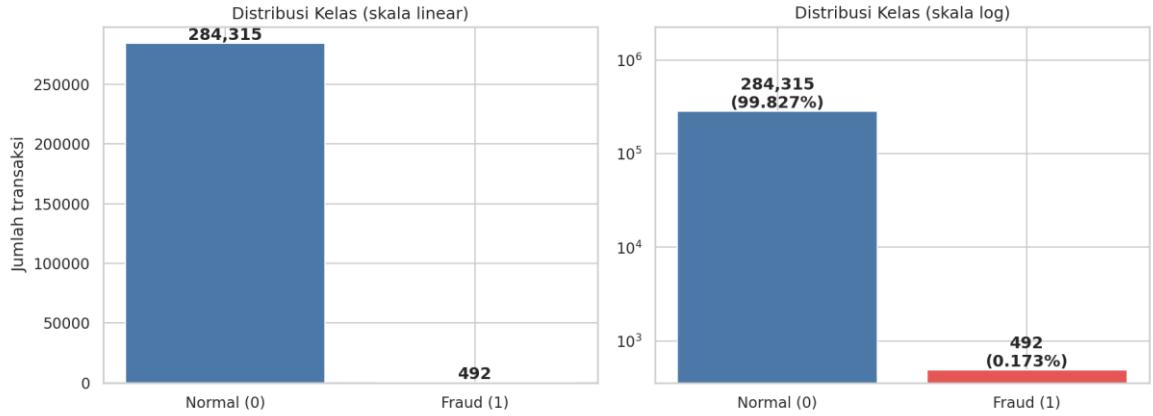
Deteksi Fraud pada Dataset Credit Card Fraud Detection (Kaggle) | 5054251027 - Faiz Farrosian Karim

1. Pendahuluan

Praktikum ini membangun model klasifikasi berbasis ensemble (Random Forest dan Gradient Boosting) untuk mendeteksi transaksi kartu kredit fraud pada data yang sangat tidak seimbang. Tiga pendekatan penanganan class imbalance dibandingkan terhadap model tanpa penanganan: SMOTE (oversampling), Random Undersampling, dan cost-sensitive learning (class weight). Seluruh model dievaluasi pada data uji dengan distribusi asli menggunakan precision, recall, F1-score, AUC-ROC, AUC-PR, dan confusion matrix.

2. Distribusi Kelas Awal

Dataset berisi 284.807 transaksi dengan 31 kolom (Time, V1-V28 hasil PCA, Amount, Class), tanpa missing value. Dari seluruh transaksi hanya **492 (0,1727%)** yang fraud, sedangkan **284.315 (99,8273%)** normal, atau rasio sekitar **1 : 578**. Ketimpangan ini membuat model cenderung mengabaikan kelas fraud.

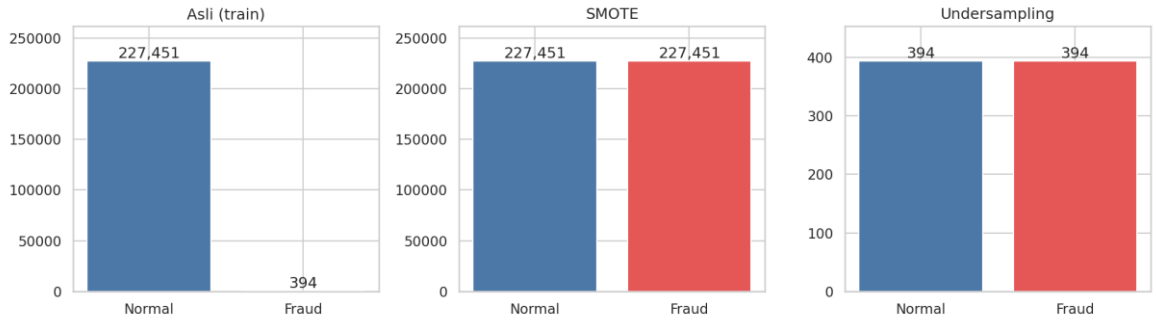


Gambar 1. Distribusi kelas pada skala linear (kiri) dan logaritmik (kanan).

3. Pendekatan Penanganan Class Imbalance

Data dibagi 80:20 dengan stratify=y (latih: 227.845 baris, 394 fraud; uji: 56.962 baris, 98 fraud; random_state=42). Kolom Time dan Amount diskalakan dengan RobustScaler yang di-fit hanya pada data latih agar tidak terjadi kebocoran data (penting bagi SMOTE yang berbasis jarak k-NN). **Resampling hanya dilakukan pada data latih**; data uji tidak diubah.

- **SMOTE**: membuat fraud sintetis hingga 227.451 vs 227.451 (rasio 1:1).
- **Random Undersampling**: mengurangi kelas normal menjadi 394 vs 394 (rasio 1:1).
- **Cost-sensitive**: data asli dengan bobot kelas seimbang (class_weight) sehingga kesalahan pada fraud dihukum lebih berat.



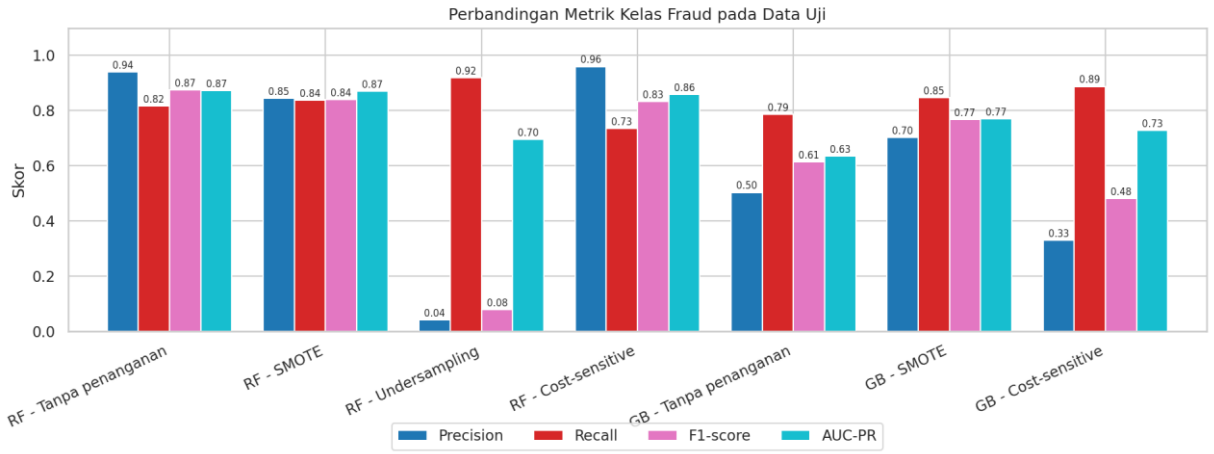
Gambar 2. Distribusi kelas data latih sebelum dan sesudah resampling.

4. Model dan Hasil Evaluasi

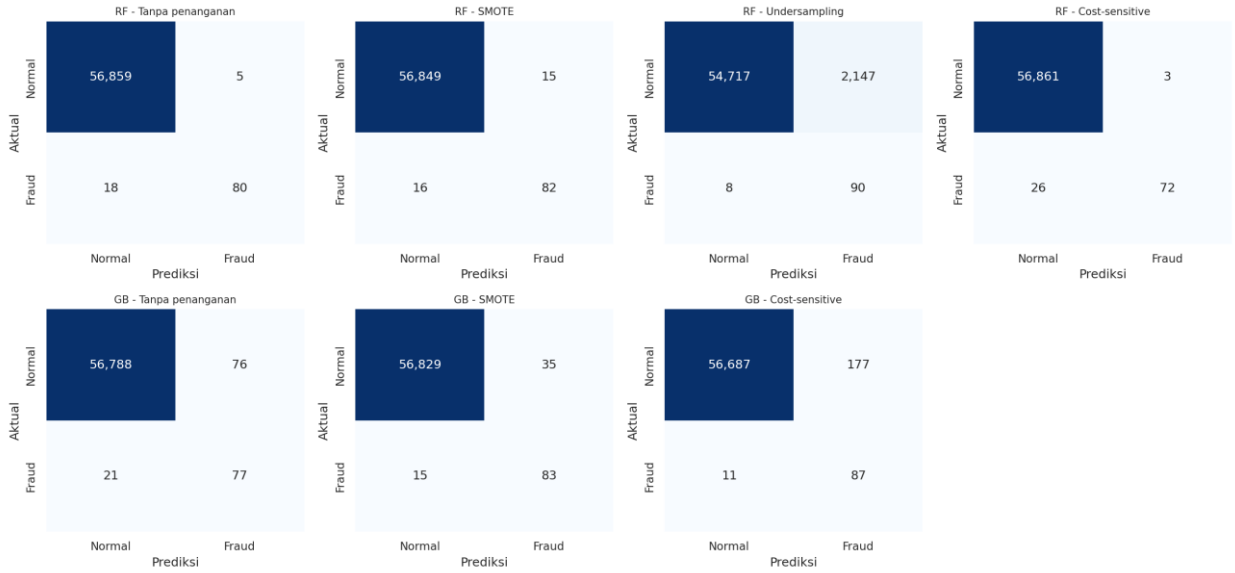
Random Forest (100 pohon) dan HistGradientBoosting (200 iterasi) dilatih pada tiap skenario data. Threshold klasifikasi 0,5. Semua metrik di bawah dihitung untuk kelas fraud pada data uji asli.

Model	Precision	Recall	F1	AUC-ROC	AUC-PR	FP	FN
RF - tanpa penanganan	0,941	0,816	0,874	0,963	0,873	5	18
RF - SMOTE	0,845	0,837	0,841	0,973	0,871	15	16
RF - Undersampling	0,040	0,918	0,077	0,978	0,695	2.147	8
RF - Cost-sensitive	0,960	0,735	0,832	0,948	0,860	3	26
GB - tanpa penanganan	0,503	0,786	0,614	0,835	0,634	76	21
GB - SMOTE	0,703	0,847	0,769	0,937	0,770	35	15
GB - Cost-sensitive	0,330	0,888	0,481	0,968	0,728	177	11

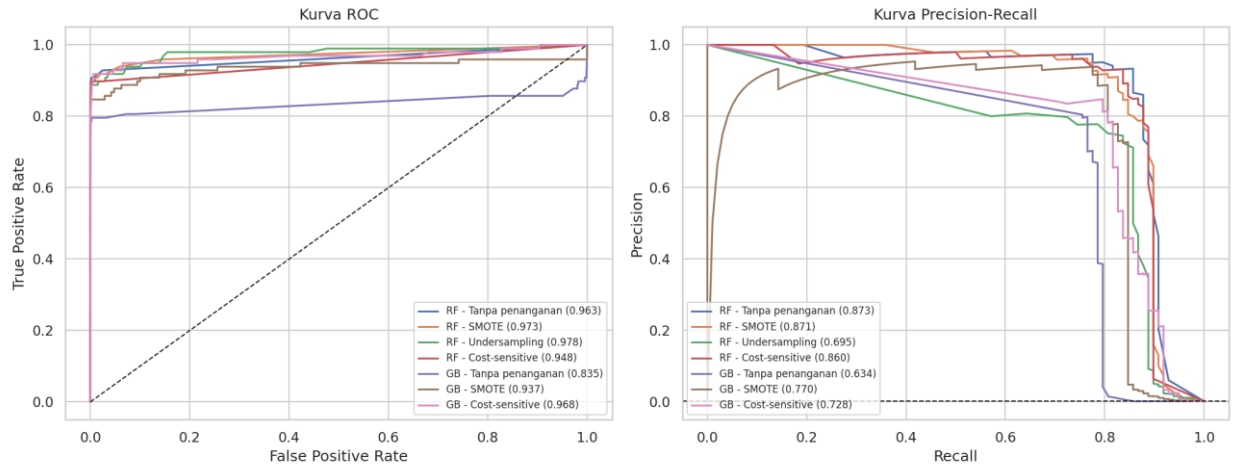
Tabel 1. Metrik kelas fraud pada data uji (98 fraud dari 56.962 transaksi). FP = false positive, FN = false negative.



Gambar 3. Perbandingan precision, recall, F1-score, dan AUC-PR antar model.



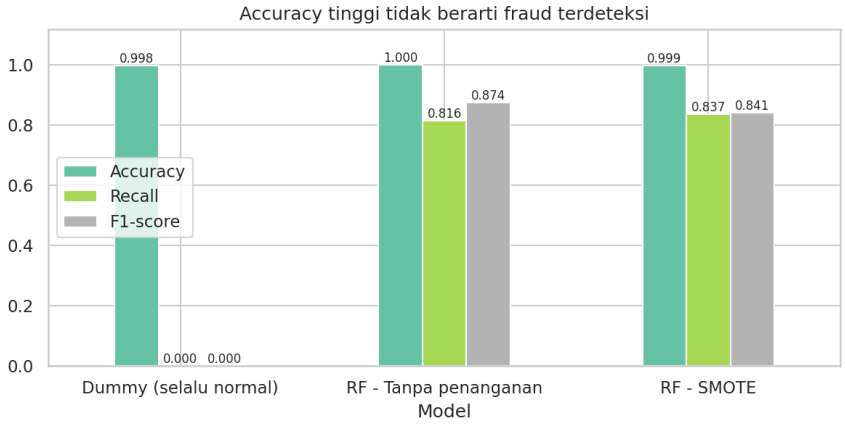
Gambar 4. Confusion matrix seluruh model pada data uji.



Gambar 5. Kurva ROC (kiri) dan Precision-Recall (kanan); angka di legenda adalah AUC.

5. Mengapa Accuracy Saja Tidak Cukup?

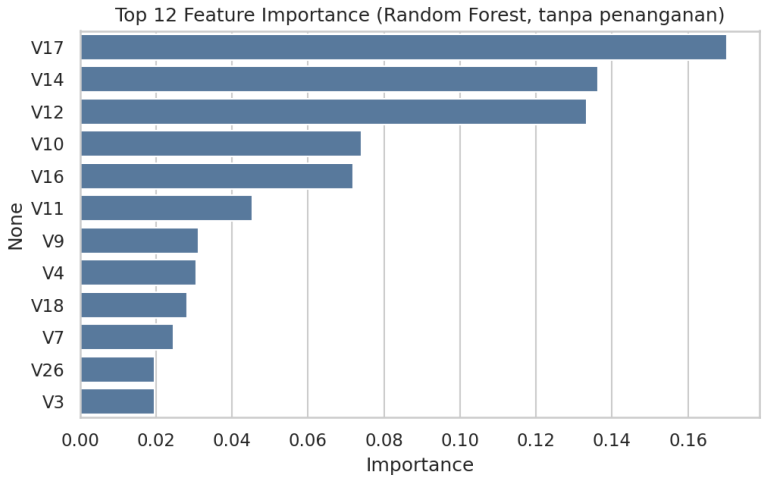
Karena 99,83% transaksi normal, model dummy yang selalu menebak "normal" mencapai **accuracy 99,83%** namun **recall 0**: tidak satu pun dari 98 fraud terdeteksi. Random Forest terbaik hanya naik ke 99,96%, selisih yang kecil padahal perbedaan kemampuan deteksinya sangat besar. Accuracy didominasi kelas mayoritas, sehingga metrik yang berfokus pada kelas fraud (precision, recall, F1, AUC-PR) wajib digunakan. AUC-PR lebih informatif daripada AUC-ROC pada data sangat timpang karena tidak dipengaruhi jumlah true negative yang sangat besar.



Gambar 6. Accuracy hampir sama, namun recall dan F1 sangat berbeda.

6. Analisis Perbandingan

- **Random Forest tanpa penanganan sudah sangat kuat** (F1 0,874; AUC-PR 0,873; hanya 5 false positive). Pohon dalam yang dirata-ratakan menangani 394 fraud latih cukup baik pada threshold 0,5.
- **SMOTE pada Random Forest** menggeser trade-off: recall naik (0,816 menjadi 0,837) dan AUC-ROC naik (0,963 menjadi 0,973), tetapi precision turun (0,941 menjadi 0,845) karena false positive bertambah dari 5 menjadi 15. F1 dan AUC-PR praktis setara.
- **Undersampling** memberi recall tertinggi (0,918) dan AUC-ROC tertinggi (0,978), tetapi dengan membuang 99,8% data normal model menghasilkan 2.147 false positive (precision 0,040). Dalam praktik ini berarti ribuan transaksi sah terblokir, sehingga tidak layak.
- **Cost-sensitive** pada Random Forest menaikkan precision (0,960; hanya 3 false positive) tetapi recall turun (0,735), yakni lebih konservatif.
- **Gradient Boosting** sangat diuntungkan: SMOTE menaikkan F1 dari 0,614 menjadi 0,769 dan AUC-PR dari 0,634 menjadi 0,770. Cost-sensitive mencapai recall 0,888 namun precision 0,330 (177 false positive). Boosting tanpa penanganan memiliki probabilitas keluaran yang kurang terkalibrasi untuk kelas langka (AUC-ROC 0,835).
- **Fitur paling berpengaruh** (Random Forest) adalah V17, V14, V12, V10, dan V16.



Gambar 7. Top 12 feature importance Random Forest.

Keterbatasan. Data uji hanya memuat 98 fraud, sehingga selisih satu atau dua deteksi mengubah recall sekitar 1 poin; perbedaan kecil antar varian Random Forest berada dalam ketidakpastian satu kali split. Pengulangan dengan stratified cross-validation akan memberi kesimpulan lebih stabil. Threshold 0,5 juga tidak dioptimalkan; pemilihan threshold sebaiknya mengikuti biaya bisnis fraud lolos versus transaksi sah yang diblokir.

7. Kesimpulan

Ensemble method efektif mendeteksi fraud: Random Forest mencapai F1 fraud sekitar 0,84-0,87 dengan precision di atas 0,84. Teknik penanganan imbalance tidak selalu menaikkan semua metrik, tetapi **menggeser titik operasi** model. SMOTE memberi keseimbangan terbaik (peningkatan nyata pada Gradient Boosting dan recall serta AUC-ROC lebih tinggi pada Random Forest), cost-sensitive cocok bila false positive mahal, dan undersampling hanya menarik bila recall adalah satu-satunya prioritas. Evaluasi harus memakai metrik kelas minoritas dan resampling harus dibatasi pada data latih untuk menghindari kebocoran data.