

Laporan Praktikum Pra-Pemrosesan Data

Dataset: House Prices - Advanced Regression Techniques (train.csv)

Item	Keterangan
Nama	Faiz Farrosian Karim
Program Studi	Rekayasa Kecerdasan Artifisial
Dataset	House Prices - Advanced Regression Techniques (Kaggle), train.csv

1. Tujuan Praktikum

- Memahami dan menerapkan langkah-langkah praproses data seperti pembersihan, transformasi, dan reduksi data.
- Meningkatkan kualitas data melalui penanganan nilai yang hilang dan data yang tidak konsisten.
- Menerapkan teknik transformasi data seperti normalisasi dan encoding.


2. Deskripsi Dataset

Dataset yang digunakan adalah House Prices - Advanced Regression Techniques dari Kaggle, yang berisi data harga rumah beserta atribut-atributnya seperti ukuran tanah, tahun dibangun, kualitas material, dan kondisi rumah. File yang digunakan adalah train.csv yang terdiri dari 1460 baris data dan 81 kolom atribut, termasuk atribut target SalePrice (harga jual rumah).

3. Pembersihan Data

3.1 Pemeriksaan Nilai Hilang

Pemeriksaan nilai hilang (missing value) dilakukan pada seluruh atribut menggunakan pandas. Hasilnya menunjukkan terdapat 19 atribut yang memiliki nilai hilang, dengan atribut PoolQC, MiscFeature, Alley, Fence, dan MasVnrType memiliki proporsi nilai hilang lebih dari 50%.



Gambar 1. Persentase nilai hilang per atribut

Atribut	Jumlah Hilang	Persentase
PoolQC	1453	99.5%
MiscFeature	1406	96.3%
Alley	1369	93.8%
Fence	1179	80.8%
MasVnrType	872	59.7%

3.2 Penanganan Nilai Hilang


Kelima atribut dengan nilai hilang di atas 50% dibuang dari dataset, sehingga jumlah kolom berkurang dari 81 menjadi 76. Untuk nilai hilang yang tersisa pada atribut lain (misalnya LotFrontage, GarageType, BsmtQual, dan Electrical), dilakukan imputasi:

- Atribut numerik diisi dengan nilai median, karena median lebih tahan terhadap pengaruh outlier dibanding rata-rata.
- Atribut kategorik diisi dengan nilai modus (nilai yang paling sering muncul).

Setelah proses ini, tidak ada lagi nilai yang hilang pada dataset (total missing value = 0).

4. Deteksi dan Penanganan Outlier

Deteksi outlier dilakukan menggunakan boxplot pada lima atribut numerik penting: SalePrice, GrLivArea, LotArea, TotalBsmtSF, dan 1stFlrSF.




Gambar 2. Boxplot atribut numerik sebelum penanganan outlier

Outlier dihitung menggunakan metode IQR (Interquartile Range), yaitu nilai di luar rentang $[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$ dianggap sebagai outlier.

Atribut	Jumlah Outlier
SalePrice	61
GrLivArea	31
LotArea	69
TotalBsmtSF	61
1stFlrSF	20

Keputusan yang diambil adalah menyesuaikan (capping/winsorizing) nilai outlier ke batas bawah/atas IQR, bukan menghapus baris datanya. Alasannya:

- Dataset hanya berjumlah 1460 baris, sehingga penghapusan baris outlier akan mengurangi jumlah data secara signifikan.
- Rumah dengan ukuran atau harga ekstrem tetap merupakan data yang valid, bukan kesalahan input data.
- Dengan capping, pengaruh nilai ekstrem berkurang tanpa kehilangan informasi baris data lainnya.



Gambar 3. Boxplot atribut numerik setelah penanganan outlier (capping)

5. Transformasi Data

5.1 Normalisasi / Standarisasi

Seluruh atribut numerik (kecuali Id dan target SalePrice) distandarisasi menggunakan StandardScaler dari scikit-learn, sehingga setiap atribut memiliki rata-rata 0 dan standar deviasi 1. Standarisasi ini penting agar atribut dengan skala nilai yang besar (misalnya LotArea) tidak mendominasi atribut dengan skala kecil (misalnya OverallQual) pada proses analisis atau pemodelan selanjutnya.

5.2 One-Hot Encoding


Terdapat 38 atribut kategorik pada dataset (setelah pembersihan). Seluruh atribut ini diubah menjadi bentuk numerik menggunakan teknik one-hot encoding, sehingga menghasilkan 197 kolom biner baru. Teknik ini digunakan karena sebagian besar algoritma machine learning hanya dapat memproses input berupa angka.

Setelah digabungkan kembali dengan atribut numerik yang telah distandarisasi, dataset hasil transformasi memiliki ukuran 1460 baris dan 235 kolom.

6. Reduksi Dimensi

6.1 Analisis Korelasi

Analisis korelasi dilakukan pada atribut numerik asli menggunakan correlation matrix untuk melihat hubungan antar atribut.



Gambar 4. Matriks korelasi atribut numerik

Ditemukan beberapa pasangan atribut dengan korelasi tinggi (>0.8):


Atribut 1	Atribut 2	Korelasi
-----------	-----------	----------

OverallQual	SalePrice	0.817
TotalBsmntSF	1stFlrSF	0.807
GrLivArea	TotRmsAbvGrd	0.836
GarageCars	GarageArea	0.882

Karena tinggi korelasi menandakan kedua atribut membawa informasi yang mirip (redundan), salah satu atribut dari tiap pasangan dibuang, yaitu 1stFlrSF, TotRmsAbvGrd, dan GarageArea. Atribut SalePrice tetap dipertahankan karena merupakan target/label yang ingin diprediksi, bukan atribut prediktor. Setelah tahap ini, jumlah kolom berkurang menjadi 232.

6.2 PCA (Principal Component Analysis)

Setelah analisis korelasi, dilakukan PCA pada seluruh fitur (tanpa Id dan SalePrice) untuk mengurangi dimensi data lebih lanjut sambil tetap mempertahankan informasi data sebanyak mungkin.



Gambar 5. Scree plot kumulatif variansi terjelaskan PCA

Berdasarkan scree plot, dibutuhkan 45 komponen utama (principal component) untuk menjelaskan minimal 90% variansi data. Artinya, dari sekitar 230 fitur, dimensi data dapat direduksi menjadi 45 fitur baru tanpa kehilangan banyak informasi penting.

7. Ringkasan Dataset Akhir

Tahapan	Jumlah Baris	Jumlah Kolom
Dataset awal	1460	81
Setelah pembersihan (drop kolom >50% missing)	1460	76
Setelah transformasi (standarisasi + one-hot encoding)	1460	235
Setelah reduksi korelasi (dataset akhir)	1460	232
Setelah PCA (opsional, komponen 90% variansi)	1460	45

Dataset akhir yang disimpan (house_prices_clean.csv) adalah dataset hasil pembersihan, transformasi, dan reduksi korelasi, dengan ukuran 1460 baris dan 232 kolom. Dataset ini tidak menggunakan hasil PCA

agar nama atribut aslinya masih dapat diinterpretasikan. Hasil PCA disimpan terpisah pada file `house_prices_pca.csv` sebagai contoh reduksi dimensi lanjutan.

8. Kesimpulan

- Dari 81 kolom awal, 5 kolom dibuang karena nilai hilangnya lebih dari 50%, dan seluruh nilai hilang yang tersisa berhasil ditangani menggunakan median dan modus.
- Outlier pada atribut numerik penting ditangani dengan metode capping berbasis IQR agar data ekstrem tidak terlalu mendominasi tanpa mengurangi jumlah baris data.
- Atribut numerik telah distandarisasi dan atribut kategorik telah diubah menjadi bentuk numerik melalui one-hot encoding.
- Reduksi dimensi melalui analisis korelasi dan PCA berhasil mengurangi jumlah fitur secara signifikan, dari 235 kolom menjadi 232 kolom (setelah reduksi korelasi) atau 45 komponen (setelah PCA), sambil tetap mempertahankan sebagian besar informasi data.
- Dataset akhir sudah bersih, konsisten, dan siap digunakan untuk tahap pemodelan (misalnya regresi untuk memprediksi SalePrice).