

Laporan Praktikum Pra-Pemrosesan Data

Dataset: House Prices - Advanced Regression Techniques (train.csv)

Nama	Faiz Farrosian Karim
NRP	5054251027

1. Tujuan Praktikum

- Memahami dan menerapkan langkah-langkah praproses data seperti pembersihan data.
- Meningkatkan kualitas data melalui penanganan nilai yang hilang dan data yang tidak konsisten.
- Mendeteksi dan menangani outlier pada atribut numerik.


2. Deskripsi Dataset

Dataset yang digunakan adalah House Prices - Advanced Regression Techniques dari Kaggle, yang berisi data harga rumah beserta atribut-atributnya seperti ukuran tanah, tahun dibangun, kualitas material, dan kondisi rumah. File yang digunakan adalah train.csv yang terdiri dari 1460 baris data dan 81 kolom atribut, termasuk atribut target SalePrice (harga jual rumah).

3. Pembersihan Data

3.1 Pemeriksaan Nilai Hilang

Pemeriksaan nilai hilang (missing value) dilakukan pada seluruh atribut menggunakan pandas. Hasilnya menunjukkan terdapat 19 atribut yang memiliki nilai hilang, dengan atribut PoolQC, MiscFeature, Alley, Fence, dan MasVnrType memiliki proporsi nilai hilang lebih dari 50%.



Gambar 1. Persentase nilai hilang per atribut

Atribut	Jumlah Hilang	Persentase
PoolQC	1453	99.5%
MiscFeature	1406	96.3%
Alley	1369	93.8%
Fence	1179	80.8%
MasVnrType	872	59.7%

3.2 Penanganan Nilai Hilang


Kelima atribut dengan nilai hilang di atas 50% dibuang dari dataset, sehingga jumlah kolom berkurang dari 81 menjadi 76. Untuk nilai hilang yang tersisa pada atribut lain (misalnya LotFrontage, GarageType, BsmtQual, dan Electrical), dilakukan imputasi:

- Atribut numerik diisi dengan nilai median, karena median lebih tahan terhadap pengaruh outlier dibanding rata-rata.
- Atribut kategorik diisi dengan nilai modus (nilai yang paling sering muncul).

Setelah proses ini, tidak ada lagi nilai yang hilang pada dataset (total missing value = 0).

4. Deteksi dan Penanganan Outlier

Deteksi outlier dilakukan menggunakan boxplot pada lima atribut numerik penting: SalePrice, GrLivArea, LotArea, TotalBsmtSF, dan 1stFlrSF.



Gambar 2. Boxplot atribut numerik sebelum penanganan outlier


Outlier dihitung menggunakan metode IQR (Interquartile Range), yaitu nilai di luar rentang $[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$ dianggap sebagai outlier.

Atribut	Jumlah Outlier
SalePrice	61
GrLivArea	31
LotArea	69
TotalBsmtSF	61
1stFlrSF	20

Keputusan yang diambil adalah menyesuaikan (capping/winsorizing) nilai outlier ke batas bawah/atas IQR, bukan menghapus baris datanya. Alasannya:

- Dataset hanya berjumlah 1460 baris, sehingga penghapusan baris outlier akan mengurangi jumlah data secara signifikan.

- Rumah dengan ukuran atau harga ekstrem tetap merupakan data yang valid, bukan kesalahan input data.
- Dengan capping, pengaruh nilai ekstrem berkurang tanpa kehilangan informasi baris data lainnya.



Gambar 3. Boxplot atribut numerik setelah penanganan outlier (capping)

5. Ringkasan Dataset Akhir

Tahapan	Jumlah Baris	Jumlah Kolom
Dataset awal	1460	81
Setelah pembersihan (drop kolom >50% missing)	1460	76
Setelah penanganan nilai hilang	1460	76
Setelah penanganan outlier (dataset akhir)	1460	76

Dataset akhir yang disimpan (house_prices_cleaned.csv) adalah dataset hasil pembersihan, dengan ukuran 1460 baris dan 76 kolom. Data masih dalam skala dan format aslinya (atribut kategorik masih berupa teks, atribut numerik belum distandarisasi), sehingga siap digunakan sebagai dasar untuk tahap transformasi (normalisasi/encoding) dan reduksi dimensi pada praktikum berikutnya.

6. Kesimpulan

- Dari 81 kolom awal, 5 kolom dibuang karena nilai hilangnya lebih dari 50%, dan seluruh nilai hilang yang tersisa berhasil ditangani menggunakan median dan modus.
- Outlier pada atribut numerik penting ditangani dengan metode capping berbasis IQR agar data ekstrem tidak terlalu mendominasi tanpa mengurangi jumlah baris data.
- Setelah tahap pembersihan, dataset akhir berukuran 1460 baris dan 76 kolom, tanpa nilai hilang dan dengan outlier yang sudah disesuaikan.
- Dataset ini sudah bersih dan konsisten, siap dilanjutkan ke tahap transformasi data (normalisasi/standarisasi dan encoding) serta reduksi dimensi pada tahap praproses berikutnya.