Laporan Praktikum: Sequential Pattern Mining pada Dataset Online Retail

Faiz Farrosian Karim - 5054251027

1. Tujuan dan Data

Tugas ini mencari **pola pembelian berurutan** pada dataset Online Retail (transaksi toko ritel online di Inggris, 2010-12-01 s/d 2011-12-09). Setiap pelanggan dijadikan satu sequence yang berisi daftar itemset (produk dalam satu invoice) yang diurutkan menurut waktu. Kolom yang dipakai: **CustomerID**, **InvoiceNo**, **InvoiceDate**, dan **Description** (item). Dataset awal berukuran 541.909 baris × 8 kolom.

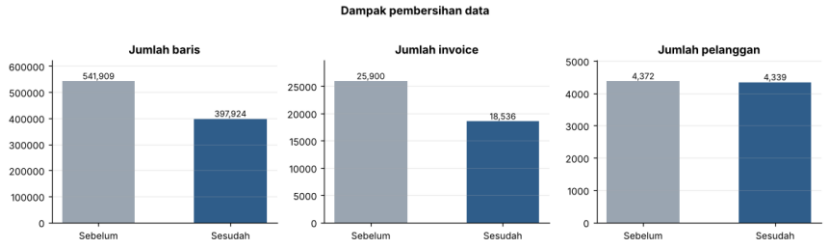
2. Eksplorasi dan Pembersihan Data

Pembersihan dilakukan bertahap sesuai ketentuan tugas. Tabel berikut menampilkan jumlah baris, invoice, dan pelanggan pada setiap tahap.

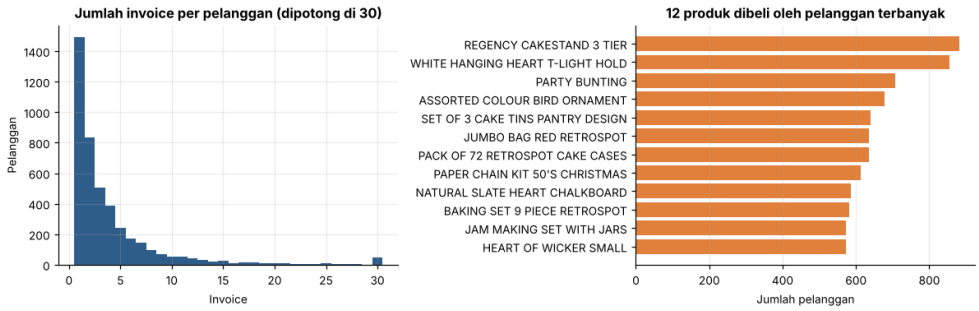
Tahap	Baris	Invoice	Pelanggan
Data awal	541.909	25.900	4.372
Hapus Description kosong	540.455	24.446	4.372
Hapus invoice batal ("C")	531.167	20.610	4.339
Hapus Quantity <= 0	530.693	20.136	4.339
Hapus CustomerID kosong	397.924	18.536	4.339

Tabel 1. Jumlah baris, invoice, dan pelanggan pada setiap tahap pembersihan.

Setelah pembersihan tersisa **397.924 baris** (26,6% dibuang), **18.536 invoice**, dan **4.339 pelanggan**. Pengurangan terbesar berasal dari CustomerID kosong (132.769 baris), karena transaksi tanpa pelanggan tidak dapat disusun menjadi sequence. Terdapat 3.866 produk unik; median pelanggan memiliki 2 invoice (rata-rata 4,27), dan 65,6% pelanggan (2.845) memiliki minimal dua invoice.



Gambar 1. Jumlah baris, invoice, dan pelanggan sebelum dan sesudah pembersihan.



Gambar 2. Sebaran invoice per pelanggan dan produk yang dibeli pelanggan terbanyak.

3. Persiapan Sequence

Data diurutkan menurut CustomerID dan InvoiceDate; produk dalam satu invoice digabung menjadi satu itemset (item unik). Hasilnya adalah 4.339 sequence dalam bentuk list of list (setiap list dalam = itemset satu invoice). Pelanggan yang hanya memiliki satu invoice tetap dihitung pada penyebut support.

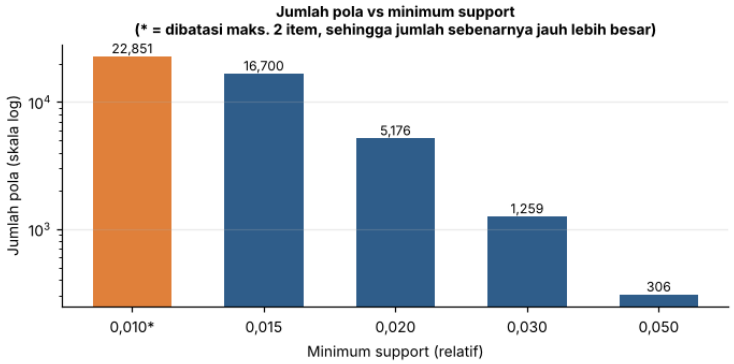
4. Penerapan Algoritma dan Pemilihan Support

PrefixSpan diimplementasikan langsung untuk sequence berisi itemset, dengan S-extension (item dibeli di invoice berikutnya) dan I-extension (item ditambahkan ke invoice yang sama), karena pustaka prefixspan hanya mendukung item tunggal. Implementasi divalidasi terhadap pustaka tersebut pada kasus yang sebanding dan menghasilkan pola serta support yang identik (1.042 pola). Support suatu pola adalah jumlah pelanggan yang memuatnya dibagi jumlah seluruh pelanggan.

Min. support	Pelanggan	Item frequent	Jumlah pola	Waktu (dtk)	Keterangan
0,010	44	1.763	22.851	13,4	dibatasi maks. 2 item; jumlah sebenarnya jauh lebih besar
0,015	66	1.350	16.700	57,9	lengkap
0,020	87	1.046	5.176	22,1	lengkap
0,030	131	657	1.259	6,9	lengkap
0,050	217	265	306	1,7	lengkap

Tabel 2. Jumlah pola pada beberapa nilai min. support.

Alasan penyesuaian. Pada 0,01 (44 pelanggan) sudah terdapat lebih dari 22.800 pola hanya untuk panjang paling banyak 2 item, dan lebih dari 59.000 untuk maksimal 3 item; proses penuh tidak selesai dalam waktu wajar. Jumlah itu terlalu besar untuk dievaluasi dan banyak pola hanya didukung puluhan pelanggan sehingga rentan kebetulan. Pada 0,05 hanya tersisa 306 pola (paling panjang 3 item), terlalu sedikit untuk menggambarkan variasi perilaku. **Nilai 0,02** (87 pelanggan) dipilih: menghasilkan **5.176 pola** (hingga 6 item), dapat dihitung penuh, dan setiap pola didukung minimal 87 pelanggan.



Gambar 3. Jumlah pola menurut min. support (skala log).

5. Evaluasi Pola Berurutan

Support = pelanggan yang memuat pola / seluruh pelanggan. **Confidence** = support(pola) / support(antecedent), dengan antecedent adalah pola tanpa item terakhir. **Lift** = confidence / support(item terakhir); lift > 1 berarti pola lebih sering terjadi daripada kebetulan. Dari 4.130 pola dengan minimal 2 item, 2.976 adalah pola **berurutan** (minimal dua invoice) dan 1.154 adalah pola co-purchase dalam satu invoice. Median confidence pola berurutan 0,40, dan 99% di antaranya memiliki lift > 1 (median 4,27).

20 pola berurutan dengan support tertinggi

#	Pola berurutan	Pelanggan	Support	Confidence	Lift
1	WHITE HANGING HEART T-LIGHT HOLDER → WHITE HANGING HEART T-LIGHT HOLDER	405	0,093	0,473	2,40
2	REGENCY CAKESTAND 3 TIER → REGENCY CAKESTAND 3 TIER	330	0,076	0,375	1,84
3	JUMBO BAG RED RETROSPOT → JUMBO BAG RED RETROSPOT	312	0,072	0,491	3,36
4	ASSORTED COLOUR BIRD ORNAMENT → ASSORTED COLOUR BIRD ORNAMENT	291	0,067	0,429	2,75
5	PARTY BUNTING → PARTY BUNTING	280	0,065	0,395	2,42
6	LUNCH BAG RED RETROSPOT → LUNCH BAG RED RETROSPOT	276	0,064	0,519	4,23
7	LUNCH BAG BLACK SKULL. → LUNCH BAG BLACK SKULL.	229	0,053	0,500	4,74

#	Pola berurutan	Pelanggan	Support	Confidence	Lift
8	SET OF 3 CAKE TINS PANTRY DESIGN → SET OF 3 CAKE TINS PANTRY DESIGN	225	0,052	0,352	2,38
9	WHITE HANGING HEART T-LIGHT HOLDER → WHITE HANGING HEART T-LIGHT HOLDER → WHITE HANGING HEART T-LIGHT HOLDER	222	0,051	0,548	2,78
10	LUNCH BAG RED RETROSPOT → LUNCH BAG BLACK SKULL.	212	0,049	0,398	3,78
11	LUNCH BAG CARS BLUE → LUNCH BAG RED RETROSPOT	209	0,048	0,436	3,56
12	LUNCH BAG BLACK SKULL. → LUNCH BAG RED RETROSPOT	208	0,048	0,454	3,70
13	LUNCH BAG RED RETROSPOT → LUNCH BAG SPACEBOY DESIGN	207	0,048	0,389	3,45
14	SPOTTY BUNTING → SPOTTY BUNTING	207	0,048	0,363	2,75
15	REGENCY CAKESTAND 3 TIER → SET OF 3 REGENCY CAKE TINS	206	0,047	0,234	2,15
16	LUNCH BAG CARS BLUE → LUNCH BAG CARS BLUE	205	0,047	0,428	3,88
17	LUNCH BAG RED RETROSPOT → LUNCH BAG SUKI DESIGN	203	0,047	0,382	4,15
18	LUNCH BAG PINK POLKADOT → LUNCH BAG RED RETROSPOT	201	0,046	0,453	3,69
19	HEART OF WICKER SMALL → HEART OF WICKER SMALL	201	0,046	0,351	2,66
20	JUMBO BAG RED RETROSPOT → JUMBO BAG VINTAGE DOILY	201	0,046	0,317	3,78

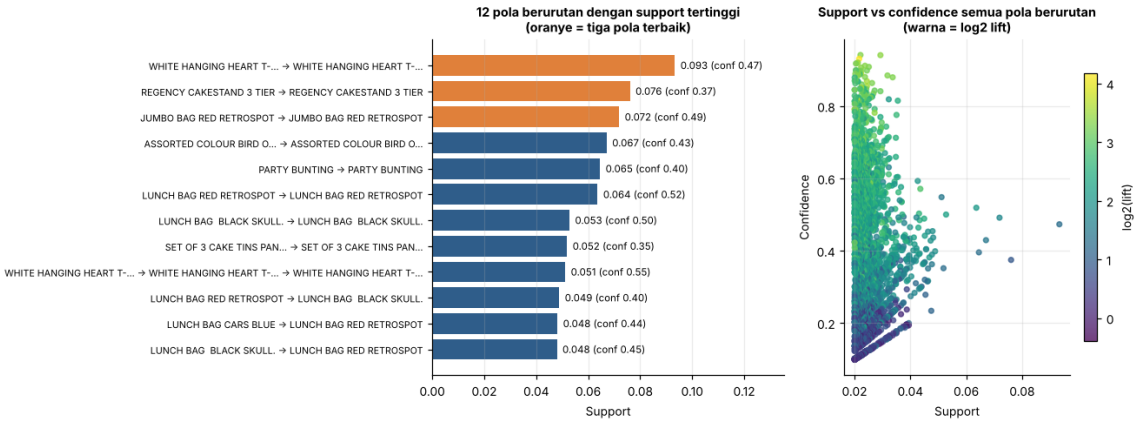
Tabel 3. Pola berurutan teratas menurut support (min. support 0,02).

Tiga pola terbaik (support tertinggi)

#	Pola berurutan	Pelanggan	Support	Confidence	Lift
1	WHITE HANGING HEART T-LIGHT HOLDER → WHITE HANGING HEART T-LIGHT HOLDER	405	0,093	0,473	2,40
2	REGENCY CAKESTAND 3 TIER → REGENCY CAKESTAND 3 TIER	330	0,076	0,375	1,84
3	JUMBO BAG RED RETROSPOT → JUMBO BAG RED RETROSPOT	312	0,072	0,491	3,36

Ketiganya adalah **pembelian ulang produk yang sama** pada invoice yang lebih belakang, dengan lift jauh di atas 1.

- **White Hanging Heart T-Light Holder → White Hanging Heart T-Light Holder** (support 0,093; confidence 0,473; lift 2,40). Sekitar 9,3% pelanggan membeli ulang produk ini, dan 47,3% dari pembelinya kembali membeli. Produk dekorasi/hadiah berputar cepat, sehingga cocok untuk pengingat restock, diskon volume, dan stok pengaman.
- **Regency Cakestand 3 Tier → Regency Cakestand 3 Tier** (support 0,076; confidence 0,375; lift 1,85). Pembeli yang kembali kemungkinan membeli untuk dijual lagi atau sebagai hadiah. Lift terendah karena produknya sudah sangat populer. Produk ini juga muncul pada pola lintas produk Regency Cakestand → Set of 3 Regency Cake Tins (support 0,047), sehingga dapat ditawarkan dalam satu koleksi.
- **Jumbo Bag Red Retrospot → Jumbo Bag Red Retrospot** (support 0,072; confidence 0,491; lift 3,36). Hampir separuh pembeli membelinya lagi. Tas adalah barang habis-pakai dan mudah dijual kembali, sehingga cocok untuk harga grosir bertingkat dan promosi pembelian ulang.



Gambar 4. Pola berurutan teratas (kiri) serta sebaran support dan confidence seluruh pola berurutan (kanan).

Pola lintas produk dengan support tertinggi (selain pembelian ulang)

#	Pola lintas produk (produk berbeda)	Pelanggan	Support	Confidence	Lift
1	LUNCH BAG RED RETROSPOT → LUNCH BAG BLACK SKULL.	212	0,049	0,398	3,78
2	LUNCH BAG CARS BLUE → LUNCH BAG RED RETROSPOT	209	0,048	0,436	3,56
3	LUNCH BAG BLACK SKULL. → LUNCH BAG RED RETROSPOT	208	0,048	0,454	3,70
4	LUNCH BAG RED RETROSPOT → LUNCH BAG SPACEBOY DESIGN	207	0,048	0,389	3,45
5	REGENCY CAKESTAND 3 TIER → SET OF 3 REGENCY CAKE TINS	206	0,047	0,234	2,15
6	LUNCH BAG RED RETROSPOT → LUNCH BAG SUKI DESIGN	203	0,047	0,382	4,15
7	LUNCH BAG PINK POLKADOT → LUNCH BAG RED RETROSPOT	201	0,046	0,453	3,69
8	JUMBO BAG RED RETROSPOT → JUMBO BAG VINTAGE DOILY	201	0,046	0,317	3,78

Tabel 4. Pola berurutan antar produk berbeda. Didominasi varian motif dalam satu keluarga produk (lunch bag) dan produk pelengkap satu koleksi.

#	Pola co-purchase (dalam satu invoice)	Pelanggan	Support	Confidence	Lift
1	{PAPER CHAIN KIT 50'S CHRISTMAS, PAPER CHAIN KIT VINTAGE CHRISTMAS}	313	0,072	0,511	4,71
2	{GREEN REGENCY TEACUP AND SAUCER, ROSES REGENCY TEACUP AND SAUCER}	311	0,072	0,804	8,24
3	{GREEN REGENCY TEACUP AND SAUCER, PINK REGENCY TEACUP AND SAUCER}	282	0,065	0,729	9,91
4	{HEART OF WICKER LARGE, HEART OF WICKER SMALL}	276	0,064	0,569	4,31
5	{RED HANGING HEART T-LIGHT HOLDER, WHITE HANGING HEART T-LIGHT HOLDER}	273	0,063	0,709	3,59

Tabel 5. Pola itemset dalam satu invoice (bukan urutan antar waktu), ditampilkan sebagai pembanding.

6. Kesimpulan

- Setelah pembersihan diperoleh 397.924 baris, 18.536 invoice, dan 4.339 pelanggan; 65,6% pelanggan memiliki minimal dua invoice sehingga layak untuk analisis pola berurutan.
- Min. support 0,01 menghasilkan terlalu banyak pola dan 0,05 terlalu sedikit; nilai 0,02 menghasilkan 5.176 pola yang dapat dievaluasi.
- Pola dengan support tertinggi adalah **pembelian ulang produk yang sama** (support 7,2%–9,3%, confidence 37,5%–49,1%). Pola lintas produk didominasi **varian dalam satu keluarga produk** (lunch bag) dan **produk pelengkap satu koleksi** (Regency).
- Hampir semua pola berurutan memiliki lift > 1 (99%), sehingga pola tersebut mencerminkan kecenderungan nyata, bukan sekadar popularitas produk.
- Implikasi bisnis: pengingat restock dan diskon volume untuk produk berulang, serta rekomendasi varian dan bundling koleksi pada pembelian berikutnya.

- Keterbatasan: item didefinisikan dengan Description (varian dihitung terpisah), data hanya satu tahun dan musiman (Natal), banyak pelanggan adalah pedagang grosir sehingga pembelian ulang dapat berarti restock, dan tidak ada batasan jarak waktu antar-invoice.